

PROJET ACTUARIAT PRICING IARD

Tarification Assurance Multirisque Habitation

Modélisation GLM & Machine Learning

Ayoub BENHASSAN

MBA Finance Quantitative

ESLSCA Business School

a.benhassan@etudiant.eslsca.fr

Février 2026

1 Introduction et objectifs

1.1 Contexte

L'actuariat pricing consiste à déterminer le **prix juste** d'un contrat d'assurance. Ce projet porte sur l'assurance **MRH (Multirisque Habitation)** qui couvre les risques liés au logement : dégâts des eaux, vol, incendie, responsabilité civile.

1.2 Objectifs

1. **Analyser la sinistralité** : comprendre les facteurs de risque
2. **Construire des modèles GLM** : fréquence (Poisson) et sévérité (Gamma)
3. **Benchmark Machine Learning** : Random Forest et XGBoost
4. **Construire un zonier tarifaire** et analyser l'impact

1.3 Données utilisées

Le jeu de données contient **200 000 observations** (50 000 contrats $\times$ 4 années) :

Variable	Type	Description
nb_sinistres	Entier	Nombre de sinistres survenus
cout_sinistre	Réel	Coût total des sinistres (€)
type_logement	Catégorielle	Appartement / Maison
zone_geo	Catégorielle	Rural / Périurbain / Urbain / Paris IDF
age_assure, surface_m2	Entier	Caractéristiques de l'assuré et du bien
exposition	Réel	Durée de couverture (en années)

2 Rappels théoriques : formules clés

Prime Pure

$$\text{Prime Pure} = \text{Fréquence} \times \text{Sévérité}$$

Sévérité

$$\text{Sévérité} = \frac{\text{Coût total}}{\text{Nb sinistres}}$$

Fréquence

$$\text{Fréquence} = \frac{\text{Nb sinistres}}{\text{Exposition}}$$

Loss Ratio

$$\text{LR} = \frac{\text{Sinistres}}{\text{Primes}} \times 100\%$$

2.1 Modèles Linéaires Généralisés (GLM)

Équation fondamentale d'un GLM

$$g(\mathbb{E}[Y]) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

où g est la fonction de lien (logarithme pour Poisson et Gamma).

Relativité (interprétation multiplicative)

$$\text{Relativité} = e^\beta$$

Exemple : $\beta = 0.26 \Rightarrow \text{Relativité} = e^{0.26} = 1.30$ soit **+30% de risque**.

GLM Fréquence avec offset

$$\ln(\mathbb{E}[N]) = \ln(\text{Exposition}) + \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$$

L'offset permet de modéliser un taux plutôt qu'un comptage brut.

2.2 Distributions et diagnostics

Variable cible	Distribution	Justification
Nombre de sinistres	Poisson	Comptage (entiers ≥ 0)
Coût des sinistres	Gamma	Valeurs positives, asymétrique

Surdispersion et critères de sélection

$\phi = \frac{\sum(\text{résidus de Pearson})^2}{\text{df}}$ Si $\phi > 1.5$: Quasi-Poisson ou Binomiale Négative.
 AIC = $2k - 2 \ln(L)$ BIC = $k \cdot \ln(n) - 2 \ln(L)$ (Plus faible = meilleur)

3 Méthodologie et processus

3.1 Pipeline de tarification en 8 étapes

1. **Cadrage** : définir le périmètre (produit MRH, objectifs)
2. **Collecte des données** : extraction sinistralité historique (3-5 ans)
3. **Préparation** : nettoyage, feature engineering, discrétisation
4. **Analyse exploratoire (EDA)** : statistiques descriptives, visualisations
5. **Modélisation GLM** : fréquence (Poisson) + sévérité (Gamma)
6. **Benchmark ML** : Random Forest, XGBoost
7. **Construction zonier** : segmentation géographique par département
8. **Analyse d'impact** : simulation révision tarifaire, gagnants/perdants

3.2 Traitement des données

Étapes de préparation

- **Calcul exposition** : $\text{Exposition} = \frac{\text{Durée contrat (jours)}}{365}$
- **Discrétisation** : âge $\rightarrow$ groupes (18-30, 31-45, 46-60, 61+)
- **Traitement outliers** : winsorisation des coûts au percentile 99%
- **Variables dérivées** : fréquence observée, prime pure, log_exposition

3.3 Construction du zonier

Credibility Weighting (lissage des relativités)

$$\text{Relativité lissée} = Z \cdot \text{Relativité brute} + (1 - Z) \cdot \text{Relativité zone}$$

où $Z = \frac{\text{Exposition}}{\text{Exposition} + k}$ est le facteur de crédibilité ($k \approx 1000$).

4 Résultats

4.1 Statistiques descriptives par segment

Zone géographique	Fréquence	Sévérité (€)	Prime Pure (€)	Relativité
Rural	8.35%	2 530	211	0.48
Périurbain	11.27%	3 114	351	0.80
Urbain	14.52%	3 949	574	1.31
Paris/IDF	16.99%	4 265	724	1.65
Moyenne	12.38%	3 548	439	1.00

Type logement	Fréquence	Sévérité (€)	Prime Pure (€)	Relativité
Appartement	9.79%	2 374	232	0.53
Maison	16.24%	4 602	747	1.70

Interprétation : Paris/IDF présente une prime pure 3.4× supérieure à la zone rurale. Les maisons ont une sinistralité 3.2× supérieure aux appartements.

4.2 Comparaison GLM vs Machine Learning

Modèle	RMSE	MAE	R ²
GLM (Fréquence × Sévérité)	245.3	189.2	0.72
Random Forest	231.8	175.4	0.76
XGBoost	225.1	168.9	0.78

Pourquoi utiliser les GLM malgré de meilleures performances ML ?

1. **Interprétabilité** : les relativités sont compréhensibles par les métiers
2. **Réglementation** : Solvabilité II exige des modèles explicables
3. **Approche hybride** : ML pour explorer et identifier des patterns, GLM pour le tarif en production

5 Conclusion

Ce projet a permis de mettre en œuvre un **pipeline complet de tarification actuarielle** pour l'assurance MRH :

- Analyse approfondie des données de sinistralité (200 000 observations)
- Modèles GLM (Poisson + Gamma) conformes aux standards actuariels
- Benchmark Machine Learning pour mesurer le potentiel d'amélioration (+8% de R²)
- Zonier tarifaire en 5 zones avec lissage par crédibilité
- Framework d'analyse d'impact pour simuler les révisions tarifaires

5.1 Compétences mobilisées

Domaine	Compétences
Actuariat	Tarification, GLM, surdispersion, zonier, credibility
Data Science	Python, Pandas, Statsmodels, Scikit-learn, XGBoost
Statistiques	Régression, validation croisée, métriques (RMSE, AIC)
Business	Interprétation métier, analyse d'impact, présentation

Projet réalisé par Ayoub BENHASSAN
MBA Finance Quantitative - ESLSCA Business
School

GitHub :
github.com/BENHASSANayoub/actuariat-pricing-iard